

# Estatística Matemática

## Verossimilhança

---



**Prof. Paulo Cerqueira Jr - cerqueirajr@ufpa.br**

**Faculdade de Estatística - FAEST**

**Programa de Pós-Graduação em Matemática e Estatística - PPGME**

**Instituto de Ciências Exatas e Naturais - ICEN**

<https://github.com/paulocerqueirajr> 

# Modelos estadísticos

# Modelos Estatísticos

- Nosso ponto de partida será um estudo empírico (pode ser experimental ou observacional) que irá fornecer certo conjunto de dados (amostra) que denotamos por  $\mathbf{y}$ . Nos casos mais simples,  $\mathbf{y} = (y_1, y_2, \dots, y_n)'$ .

**Suposição fundamental:** considere  $\mathbf{y}$  como um valor obtido de uma vetor aleatório  $Y$ .

- Nosso objetivo é usar  $\mathbf{y}$  para tirar conclusões sobre a distribuição desconhecida  $F(\cdot)$  de  $Y$ .
- Nossas conclusões sobre  $F(\cdot)$  estão sujeitas à incerteza dado a aleatoriedade governando  $Y$  (que irá produzir  $\mathbf{y}$ ). Devemos certificar que:
  - O nível de incerteza é o menor possível, considerando a aleatoriedade de  $Y$ .
  - Somos capazes de avaliar o nível de incerteza em nossas conclusões.

# Modelos Estatísticos

- A natureza física do fenômeno que gera  $\mathbf{y}$ , o esquema de amostragem, e outras informações, irão colocar limites no conjunto de possíveis escolhas para  $F(\cdot)$ .
- Este conjunto (denotado por  $\mathcal{F}$ ) é chamado de modelo estatístico.
- É intuitivo pensar que nossas inferências serão mais precisas de formas capazes de selecionar o conjunto  $\mathcal{F}$  menor possível, sob o requerimento de que  $F \in \mathcal{F}$ .
- Em alguns casos, podemos assumir que  $Y$  é uma a. a. com componentes independentes e identicamente distribuídos. Neste caso, dizemos que  $\mathbf{y}$  é uma a.a. simples de  $Y$ .

# Modelos paramétricos

# Modelos paramétricos

- A princípio,  $\mathcal{F}$  pode ser qualquer conjunto de funções de distribuições, mas existe uma categoria de tais conjuntos que possui importante papel, tanto do ponto de vista teórico quando aplicado.
- Este caso ocorre todos os elementos de  $\mathcal{F}$  são funções com a mesma formulação matemática, identificadas apenas pelas diferentes especificações de  $\theta$ , que varia em  $\Theta \in \mathbb{R}^k$ ,

$$\mathcal{F} = \{F(\cdot \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}^k\}$$

# Modelos paramétricos

- Na grande maioria dos casos (em todos os casos que iremos considerar neste curso), toda a função de distribuição membro de  $\mathcal{F}$  refere-se a v.a. discretas ou contínuas.
- Então,  $\mathcal{F}$  pode ser definida usando as f.p. ou f.d. correspondentes.
- Podemos definir um modelo estatístico  $\mathcal{F}$  (caso contínuo) como um conjunto de f.d's

$$\mathcal{F} = \{ f(\cdot \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}^k \}$$

$\theta$  : parâmetro.

$\Theta$  : espaço paramétrico.

- $\mathcal{F}$ , indicado acima, é chamado de classe paramétrica ou modelo paramétrico.
- Portanto, os elementos de  $\mathcal{F}$  estão associados aos elementos de  $\Theta$ .
- Em particular, existe um valor  $\theta^* \in \Theta$ , associado a  $F(\cdot)$ , chamado de **valor real** do parâmetro, e nossas inferências serão sobre  $\theta^*$

# Modelos paramétricos

**Definição 1 (Espaço amostral)** É o conjunto  $\mathcal{Y}$  de todos os possíveis resultados  $y$  compatíveis com o modelo paramétrico dado.

- Formalmente denotado por  $\mathcal{Y}_\theta$  o suporte (domínio) da densidade  $f(\cdot; \theta)$ , o espaço amostral é dado por  $\mathcal{Y} = \bigcup_{\theta \in \Theta} \mathcal{Y}_\theta$ .
- Frequentemente, entretanto,  $\mathcal{Y}_\theta$  é o mesmo que as possíveis escolhas de  $\theta$ , e este conjunto coincidirá com  $\mathcal{Y}$ .

**Exemplo 1** Assuma que  $Y \sim \text{Binomial}(n, \theta)$ . Se  $\theta \in [0, 1]$ ,  $\mathcal{Y}_\theta$  será o mesmo para todo  $\theta$ .  $\mathcal{Y}_\theta$  coincidirá com o espaço amostral  $\mathcal{Y} = \{0, 1, 2, \dots, n\}$ .

- Se  $\theta \in [0, 1]$ , então  $\mathcal{Y}_{\theta=0} = \{0\}$ ,  $\mathcal{Y}_{\theta=1} = \{n\}$  e  $\mathcal{Y}_{\theta \in (0,1)} = \{0, 1, \dots, n\}$ .
- Neste caso,  $\mathcal{Y} = \bigcup_{\theta \in [0,1]} \mathcal{Y}_\theta = \{0, 1, \dots, n\}$ .



# Modelos paramétricos

**Exemplo 2** Se dois valores são amostrados independentemente da  $N(\theta, 1)$ , então  $\mathbf{y} = (y_1, y_2)^\top$ , onde  $y_i \in \mathbb{R}$  ( $i = 1, 2$ ),

$$\mathcal{Y} = \mathbb{R} \times \mathbb{R}, \quad Y \sim N \begin{bmatrix} \theta \\ \theta \end{bmatrix}, I_2,$$

em que,

$$f(y; \theta) = \phi(y_1 - \theta)\phi(y_2 - \theta)$$

- Se não houver qualquer restrição para  $\theta$ , temos  $\Theta = \mathbb{R}$ .
- Se existir restrição (ex. sabemos que  $\theta > 0$ )

# Famílias de locação e escala

# Famílias de locação e escala

- Aqui discutiremos três técnicas para construir famílias de distribuições.
- As famílias resultantes possuem interpretações físicas diretas que as tornam úteis para modelagem, além de apresentarem propriedades matemáticas convenientes. Considere apenas o caso contínuo.
- Os 3 tipos de famílias são:
  - i. locação;
  - ii. Iscala e
  - iii. locação e escala.
- Cada família é construída pela especificação de uma f.d  $f(x)$  chamada de densidade padrão da família.
- Todas as outras densidades da família podem ser geradas pela transformação da densidade padrão.

# Famílias de locação e escala

**Teorema 1** Seja  $f(x)$  qualquer f.d. e considere  $\mu$  e  $\sigma > 0$  como constantes conhecidas.

Então, a função  $g(x|\mu, \sigma) = \frac{1}{\sigma} f\left(\frac{x - \mu}{\sigma}\right)$  é uma f.d.

**Prova:** Para verificar que a transformação produziu um f.d. legítima, precisamos verificar que

$$\frac{1}{\sigma} f\left(\frac{x - \mu}{\sigma}\right)$$

se é:

1. não negativa;

2. integra 1.

- Logo, em relação a 1., tem-se

$f(x)$  é uma f.d.  $\Rightarrow f(x) > 0, \forall x$ , então  $\frac{1}{\sigma} f\left(\frac{x - \mu}{\sigma}\right) > 0$ , para todos os valores de  $x, \mu$  e  $\sigma$ .

# Famílias de Locação e Escala.

- Referente a 2.

$$\int_{-\infty}^{\infty} \frac{1}{\sigma} f\left(\frac{x - \mu}{\sigma}\right) dx, \quad y = \frac{x - \mu}{\sigma} \text{ e } dy = \frac{1}{\sigma}.$$

Logo,

$$\int_{-\infty}^{\infty} \frac{1}{\sigma} f(y) \sigma dy = \int_{-\infty}^{\infty} f(y) dy = 1.$$

# Famílias de Locação e Escala.

**Definição 2** Seja  $f(x)$  qualquer f.d., então a família de densidades  $f(x - \mu)$  indexada pelo parâmetro real  $\mu$  é chamada de **família de locação (localização)** com densidade padrão  $f(x)$ . O  $\mu$  é conhecido como **parâmetro de localização da família**.

- O parâmetro  $\mu$  simplesmente desloca a densidade  $f(x)$  de maneira que o formato do gráfico não é alterado, mas o ponto do gráfico de  $f(x)$  que estava acima de  $x = 0$ , estará agora acima de  $x = \mu$  para  $f(x - \mu)$ .

**Exemplo 3** Se  $\sigma > 0$  é especificado e definimos

$$f(x) = (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} I_{(-\infty, \infty)}(x),$$

então a família de localização com densidade padrão  $f(x)$  é o conjunto de distribuições Normais com média  $\mu$  desconhecida e variância  $\sigma^2$  conhecida.

# Famílias de Localização e Escala.


- A família Cauchy com  $\sigma$  (conhecido) e  $\mu$  (desconhecido) é outro exemplo de família de localização.
- O ponto principal da [Definição 2](#) é que podemos iniciar com qualquer densidade  $f(x)$  e gerar uma família de densidades com a introdução do parâmetro de localização.
- Se  $X$  é uma variável aleatória com densidade  $f(x - \mu)$ , então  $X$  pode ser representada como  $X = Z + \mu$ , onde  $Z$  é variável aleatória com densidade  $f(z)$ .

**Exemplo 4 (Família de localização exponencial)** Seja  $f(x) = e^{-x}$  para todo  $x \geq 0$  e  $f(x) = 0$  para  $x < 0$ .

Para formar uma família de localização devemos substituir  $x$  por  $x - \mu$

$$f(x) = \begin{cases} e^{-(x-\mu)} & x - \mu \geq 0 \\ 0 & x - \mu < 0 \end{cases} = \begin{cases} e^{-(x-\mu)} & x \geq \mu \\ 0 & x < \mu \end{cases}$$

# Famílias de Localização e Escala.






# Famílias de Localização e Escala

**Definição 3** Seja  $f(x)$  qualquer f.d., então para qualquer  $\sigma > 0$ , a família de densidades  $1/\sigma f[x/\sigma]$  indexada pelo parâmetro  $\sigma$  é chamada de **família de escala** com densidade padrão  $f(x)$  e parâmetro de escala  $\sigma$ .

- O efeito de introduzir  $\sigma$  é tanto esticar ( $\sigma > 1$ ) quanto contrair ( $\sigma < 1$ ) o gráfico  $f(x)$  a forma básica é mantida.

# Famílias de Localização e Escala



# Famílias de Localização e Escala

**Exemplo 5**  $Ga\left(\alpha, \beta = \frac{1}{\sigma}\right)$  com  $\alpha$  conhecido e  $\beta = \frac{1}{\sigma}$  onde  $\sigma$  é desconhecido.

A densidade padrão  $Ga(\alpha, \beta = 1)$

$$f(x|\alpha, \beta = 1) = \frac{1}{\Gamma(\alpha)} x^{\alpha-1} \exp\{-x\} I_{(-\infty, \infty)}(x).$$

Logo,

$$f(x/\sigma) = \frac{1}{\Gamma(\alpha)} \frac{x^{\alpha-1}}{\sigma^{\alpha-1}} \exp\left\{-\frac{x}{\sigma}\right\} I_{(-\infty, \infty)}(x)$$
$$1/\sigma f(x/\sigma) = \frac{1}{\sigma^\alpha} \frac{1}{\Gamma(\alpha)} x^{\alpha-1} \exp\left\{-\frac{x}{\sigma}\right\} I_{(-\infty, \infty)}(x)$$

# Famílias de Localização e Escala

**Exemplo 6** Família Normal com  $\mu = 0$  e  $\sigma^2$  desconhecido.

A densidade padrão  $N(0, 1)$

$$f(x) = 1 * (2\pi)^{-1/2} \exp\left\{-\frac{1}{2(1)}x^2\right\} I_{(-\infty, \infty)}(x),$$

Logo,

$$f(x/\sigma) = (2\pi)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} I_{(-\infty, \infty)}(x)$$

$$1/\sigma f(x/\sigma) = (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(x - \mu)^2\right\} I_{(-\infty, \infty)}(x)$$

# Famílias de Localização e Escala


**Definição 4** Seja  $f(x)$  qualquer f.d., então para qualquer  $\mu$  real e qualquer  $\sigma > 0$  a família de densidades

$$\frac{1}{\sigma} f \left[ \frac{(x - \mu)}{\sigma} \right],$$

indexadas pelos parâmetros  $(\mu, \sigma)$ , é chamada de família de localização e escala com densidade padrão  $f(x)$ . Neste caso,  $\mu$  é o parâmetro de localização e  $\sigma$  é o parâmetro de escala.

- Efeito da inclusão dos parâmetros:
  - $\mu$  irá deslocar o gráfico de maneira que o ponto que estava acima de 0, agora fica acima de  $\mu$ .
  - $\sigma$  irá esticar ( $\sigma > 1$ ) ou contrair ( $\sigma < 1$ ) o gráfico de  $f(x)$ .

# Famílias de Localização e Escala



# Famílias de Locação e Escala

- O seguinte teorema relaciona a transformação da f.d.  $f(x)$ , que define uma família de locação e escala, com a transformação da variável aleatória  $Z$  com densidade  $f(z)$ .

**Teorema 2** Seja  $f(\cdot)$  qualquer f.d. e considere  $\mu \in \mathbb{R}$  e  $\sigma \in \mathbb{R}^+$ . Então  $X$  é uma v.a. com densidade  $1/\sigma f[(x - \mu)/\sigma]$ , se e somente se, existe uma v.a.  $Z$  com densidade  $f(z)$  e  $X = \sigma Z + \mu$ .

- No **Teorema 2**:
  - Se  $\sigma = 1$ : família de locação (apenas).
  - Se  $\mu = 0$ : família de escala (apenas).

# Famílias de Localização e Escala

- Fato importante a ser extraído do **Teorema 12** é que  $Z = \frac{X - \mu}{\sigma}$ , tem f.d.

$$f_Z(z) = \frac{1}{1} f\left(\frac{z - 0}{1}\right) = f(z),$$

isto é, a distribuição de  $Z$  é membro da família de localização escala com  $\mu = 0$  e  $\sigma = 1$ .

- Frequentemente, cálculos são desenvolvidos para a v.a. padrão  $Z$  com f.d  $f(z)$  e então o resultado correspondente para a v.a.  $X$  com f.d.  $1/\sigma f[(x - \mu)/\sigma]$  pode ser facilmente derivado.



# Famílias de Localização e Escala

**Teorema 3** Seja  $Z$  uma v.a. com f.d.  $f(z)$ . Suponha que  $E(Z)$  e  $Var(Z)$  existem. Se  $X$  é uma v.a. com densidade  $1/\sigma f(x/\sigma)$ , então,

$$E(X) = \sigma E(Z) + \mu \text{ e } Var(X) = \sigma^2 Var(Z).$$

- Em particular, se  $E(Z) = 0$  e  $Var(Z) = 1$ , então,  $E(X) = \mu$  e  $Var(X) = \sigma^2$ .
- Probabilidades para qualquer membro da família de localização escala pode ser calculada em termos da variável padrão  $Z$ .

$$P(X \leq x) = P\left(\frac{X - \mu}{\sigma} \leq \frac{x - \mu}{\sigma}\right) = P\left(Z \leq \frac{x - \mu}{\sigma}\right).$$

# A função de verossimilhança

# A função de verossimilhança

- Considere o dado modelo do tipo:  $\mathcal{F} = \{f(\cdot \mid \theta) : \theta \in \Theta \subseteq \mathbb{R}^k\}$ .
- Quando um valor amostral  $y$  é observado, o valor da f.d  $f(y; \theta)$  **dependerá apenas** de  $\theta$ .
- Esta função nos parece a f.d para observar aquilo que de fato observamos ( $y$ ).
- Se precisamos estabelecer um *ranking* envolvendo dois elementos de  $\theta$  (considere  $\theta'$  e  $\theta''$ ), então uma quantidade relevante e útil para esta tarefa será a razão  $f(y; \theta') / f(y; \theta'')$ , desde que o denominador não seja zero.
- Como esta razão não muda caso ambos os termos sejam multiplicados por uma constante positiva  $C$ , independentemente de  $\theta$ , então para comparar os elementos de  $\Theta$  a quantidade relevante será proporcional a  $f(y; \theta)$ .

# A função de verossimilhança

**Definição 5** Para o modelo *[Math Processing Error]* a partir do qual uma amostra  $y \in \mathcal{Y}$  foi observada, usamos o termo **função de verossimilhança**, ou simplesmente **verossimilhança**, para a função de  $\Theta$  para  $\mathbb{R}^+ \cup \{0\}$  escrita como

$$L(\theta; y) = c(y)f(y; \theta),$$

em que  $c(y)$  : constante positiva independente de  $\theta$ .

- A verossimilhança é uma função de  $\theta$ .
- A notação  $L(\theta; y)$  é usada para enfatizar que esta função depende de  $y$ , no sentido de que para uma amostra diferente  $y'$  obteremos uma verossimilhança diferente  $L(\theta; y')$ .

# A função de verossimilhança

- Note que não importa se escrevemos  $c$  ou  $c(y)$  na definição de verossimilhança, uma vez que a verossimilhança é uma função de  $\theta$ .
- Mesmo que todo valor  $L(\theta; y)$  seja determinado por distribuições de probabilidades, a função de verossimilhança **não é uma distribuição de probabilidade**.
- $L(\theta; y)$  é uma quantidade não negativa, e na maioria dos casos é positiva para todo  $\theta$ . Sendo assim, definimos a função de log-verossimilhança como:

$$\ell(\theta; y) = \ln L(\theta; y) = c + \ln f(y; \theta),$$

com a convenção de que  $\ell(\theta; y) = -\infty$  se  $L(\theta; y) = 0$ .

# A função de verossimilhança

**Exemplo 7** Considere uma a.a.  $\mathbf{y} = (y_1, y_2, \dots, y_n)'$  da v.a.  $N(\mu, \sigma^2)$ , onde  $\theta = (\mu, \sigma^2)$  varia no espaço  $\Theta = \mathbb{R} \times \mathbb{R}^+$ .

- Devido à independência das componentes, temos,

*[Math Processing Error]*

- Qualquer constante não dependente de  $\theta$ , por exemplo,  $c = 1$ .
- Função de log-verossimilhança

*[Math Processing Error]*

# A função de verossimilhança

**Exemplo 8** Considere uma a.a.  $\mathbf{x} = (x_1, x_2, \dots, x_n)'$  da v.a.  $U(0, \theta)$ , onde  $\theta > 0$ . A f.d. associada a  $x_i$  é  $f(x_i) = \frac{1}{\theta}$ , se  $x_i \in (0, \theta)$ .

- Quando multiplicamos tais f.d.'s para obter  $L(\theta; x)$ , não podemos simplesmente multiplicar o termo  $1/\theta$  sem considerar a condição **se**  $x_i \in (0, \theta)$ .
- Portanto, escrevemos a densidade para uma única observação, como segue,

$$\frac{1}{\theta} I_{(0, \theta)}(x), \quad x \in \mathbb{R}.$$

# A função de verossimilhança

Função de verossimilhança

*[Math Processing Error]*

- Note que  $\prod_{i=1}^n I_{(0,\theta)}(x_i) = 1$ , se

*[Math Processing Error]*



# A função de verossimilhança


Assim,

*[Math Processing Error]*

A log-verossimilhança:

*[Math Processing Error]*

# A função de verossimilhança



# Princípio da verossimilhança.

- A função de verossimilhança conecta a informação pré-experimental (expressa pela escolha do modelo) com a informação experimental contida em  $y$ .
- Portanto, de certa forma, a verossimilhança contém tudo que sabemos sobre o problema de inferência em questão (sem levar em conta qualquer informação sobre  $\theta$  que, por qualquer razão, não foi acomodada no modelo, tais como opiniões pessoais ou resultado de estudos relacionados).

**Exemplo 9** O princípio da verossimilhança. Para um modelo estatístico  $\{f(\cdot \mid \theta) : \theta \in \Theta\}$  dois pontos  $y, z \in \mathcal{Y}$  tal que  $L(\theta; y) \propto L(\theta; z)$  devem levar às mesmas conclusões inferenciais.

- Esta afirmação representa a versão mais fraca do princípio da verossimilhança.
- A seguir apresentamos uma versão mais forte que diz que as conclusões coincidem mesmo quando as duas observações se referem a modelos distintos e espaços amostrais distintos.

# Princípio da verossimilhança.

**Definição 6** Considere um experimento que consiste em lançar várias vezes uma moeda, de forma independente, e seja  $\theta$  a probabilidade de ocorrer coroa  $\bar{C}$  e  $1 - \theta$  a probabilidade de ocorrer cara  $C$ .

Suponha que o resultado do experimento foi:

$$\mathbf{x} = \{\bar{C}, \bar{C}, \bar{C}, \bar{C}, \bar{C}, C, \bar{C}, \bar{C}, \bar{C}, \bar{C}, C, C\}$$

Regras de parada:

1. Lançar a moeda 12 vezes ( $n^o$  de lançamentos fixado);
2. Lançar a moeda até aparecer 3 caras;
3. Lançar a moeda até aparecerem 2 caras consecutivas;
4. Lançar a moeda até o lançador ficar cansado.

# Princípio da verossimilhança.

Em qualquer situação a verossimilhança é proporcional a

$$\theta^9 (1 - \theta)^3,$$

- Segundo o princípio da verossimilhança as inferências **devem ser a mesmas qualquer que tenha sido o processo experimental** (ou a regra de parada).

# Estatísticas Suficientes

# Estatísticas Suficientes

- Em uma descrição mais simplificada da teoria estatística, alguns poderiam dizer que seu objetivo é selecionar as **operações** mais apropriadas para serem aplicadas aos dados.
- Visto que uma variedade destas operações serão consideradas, é necessário introduzir a seguinte definição:

**Definição 7** Uma função  $T(\cdot) : y \rightarrow \mathbb{R}^R$ , para algum inteiro positivo  $r$ , tal que  $T(y)$  não depende de  $\theta$ , é chamada de **Estatística**, e o valor  $t = T(y)$  correspondendo ao valor observado  $y$  é chamado de valor amostral.

- A condição de que  $T(y)$  não dependa de  $\theta$  é necessária para assegurar que a estatística seja calculável na presença dos dados.

# Estatísticas Suficientes

**Exemplo 10** Estatísticas para uma amostra  $(y_1, y_2, \dots, y_n)$  cujos elementos pertencem a  $\mathbb{R}$ :

*[Math Processing Error]*

Obviamente, estes são apenas 3 exemplos entre inúmeros casos.



# Estatísticas suficientes

- Algumas vezes devemos considerar a imagem inversa dos valores de  $t$  de uma estatística  $T$ , isto é, conjuntos do tipo:

$$A_t = \{y : y \in \mathcal{Y}; T(y) = t\},$$

formam uma partição do espaço amostral. Fazemos referência a esta partição induzida por  $T(y)$ .

- Por exemplo, se  $T = \sum_{i=1}^n y_i$ , os conjuntos  $\{A_t\}$  serão hiperplanos paralelos uns aos outros.
- Um conjunto específico  $A_t$  é dado por todos os pontos  $\mathbf{y} = (y_1, y_2, \dots, y_n)' \in \mathbb{R}$  satisfazendo a equação  $y_1 + y_2 + \dots + y_n = t$ .

# Estatísticas suficientes

**Exemplo 11** Entre os tipos de estatísticas que iremos considerar, alguns são usados com frequência e a eles são dados nomes específicos. Para a amostra  $(y_1, y_2, \dots, y_n)'$  o  $r$ -ésimo momento amostral é a estatística de  $\mathcal{Y}$  para  $\mathbb{R}$  dada por

$$m_r = \frac{1}{n} \sum_{i=1}^n y_i^r.$$

- Em particular,  $m_1 = \frac{1}{n} \sum_{i=1}^n y_i^1$  é a média amostral  $\bar{y}$ .
- Outro exemplo de estatística é o que definimos como variância amostral:

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2,$$

que assume valores em  $\mathbb{R}^+ \cup \{0\}$ .

# Estatísticas Suficientes

- No caso da distribuição  $N(\mu, \sigma^2)$ , temos a verossimilhança indicada abaixo para uma amostra aleatória simples  $(y_1, y_2, \dots, y_n)' = \mathbf{y}$ .
- Considere  $\theta = (\mu, \sigma^2)$ ,

*[Math Processing Error]*

# Estatísticas Suficientes

- Veja que não é preciso conhecer todos os elementos individuais de  $(y_1, y_2, \dots, y_n)$  para escrever  $L(\theta; \mathbf{y})$  do *slide* anterior, dado a quantidade *[Math Processing Error]*.
- Essa função de verossimilhança é unicamente identificada, entre todas as possíveis funções de verossimilhança para o modelo estatístico escolhido, uma vez que dois valores *[Math Processing Error]* são dados.
- A questão agora é saber se tal situação favorável pode ser estendida em geral, ou pelo menos para algumas classes de modelos (neste caso, para quais classes?) A seguir, iremos examinar a natureza e propriedades daquelas estatísticas capazes de sumarizar **toda a informação** presente na função de verossimilhança.

# Estatísticas Suficientes

**Definição 8** Para o modelo  $\mathcal{F} = \{f(\cdot \mid \theta) : \theta \in \Theta\}$ , uma estatística  $T(y)$  é dita **suficiente** para  $\theta$  se assume valores em dois pontos do espaço amostral somente se estes pontos possuem verossimilhanças equivalentes. Isto é:

$$\forall y, z \in \mathcal{Y}, \quad T(y) = T(z) \Rightarrow L(\theta; y) \propto L(\theta; z), \forall \theta \in \Theta.$$

- Devemos ter em mente que a propriedade de suficiência está diretamente relacionada à escolha do modelo.
- Se o modelo é **alterado**, as estatísticas em questão podem não ser mais suficientes.
- Para qualquer modelo, sempre existirá uma estatística suficiente que será a própria amostra  $\mathbf{y} = (y_1, \dots, y_n)'$ , entretanto, esta estatística suficiente é uma escolha muito trivial e na prática é desconsiderada.

**Exemplo 12** Suponha que  $\theta$  pode assumir dois valores (0 e 1). As duas funções de verossimilhança correspondentes são fornecidas a seguir:

$\theta$	$P(Y = 0)$	$P(Y = 1)$	$P(Y = 2)$
0	8/12	1/12	3/12
1	4/12	2/12	6/12

Note que:

*[Math Processing Error]*

Estatística:

*[Math Processing Error]*

$$T(y = 1) = 0 = T(y = 2) \Rightarrow L(\theta; y = 1) \propto L(\theta; y = 2).$$

Assim,  $T(y) = I_{\{0\}}(y)$  é uma estatística suficiente para  $\theta$ .

# Estatísticas Suficientes

**Exemplo 13** Considere  $g(\cdot; \theta)$  a f.d. associada a uma a.a. simples  $\mathbf{y} = (y_1, y_2, \dots, y_n)$ .

- A função de verossimilhança pode ser escrita como

$$L(\theta; \mathbf{y}) = \prod_{i=1}^n g(y_i; \theta) = \prod_{i=1}^n g(y_{(i)}; \theta),$$

onde na última igualdade, os termos foram multiplicados após terem sido organizados de acordo com as estatísticas de ordem.

- Portanto, duas amostras com as mesmas estatísticas de ordem possuem as mesmas funções verossimilhança.
- Segue então que, para quaisquer f.d.'s  $g(\cdot; \theta)$  as estatísticas de ordem são suficientes.

# Fatoração de Neyman



# Fatoração de Neyman

- Se  $T(\cdot)$  é uma estatística suficiente, então  $L(\theta; \mathbf{y})$  depende apenas através de  $T(\mathbf{y})$ . Isto significa que existe uma função  $g$  tal que  $L(\theta; \mathbf{y}) \propto g(T(\mathbf{y})|\theta)$ .
- Note que  $L(\theta; \mathbf{y}) \propto f(\mathbf{y}|\theta)$ , logo

$$\frac{f(\mathbf{y}|\theta)}{g(T(\mathbf{y})|\theta)},$$

não dependerá de  $\theta$ .

- Denote:

$$h(\mathbf{y}) = \frac{f(\mathbf{y}|\theta)}{g(T(\mathbf{y})|\theta)},$$

portanto, se  $T(\cdot)$  é estatística suficiente, a seguinte relação será válida:  
 $f(\mathbf{y}|\theta) = h(\mathbf{y})g(T(\mathbf{y})|\theta)$ .

# Fatoração de Neyman

Teorema 4 (Teorema da Fatoração de Neyman) Para o modelo *[Math Processing Error]* a estatística  $T(\cdot)$  é suficiente para  $\theta$  se e somente se  $f(\mathbf{y}; \theta)$  pode ser escrita na forma  $f(\mathbf{y}|\theta) = h(\mathbf{y})g(T(\mathbf{y})|\theta)$  para alguma função  $g$  e  $h$ .

*i* Uma forma alternativa de interpretar a definição:

Se conhecermos o valor amostral de  $t = T(\mathbf{y})$  e escrevessemos a verossimilhança  $L_T(\theta; t)$  para o modelo estatístico associado a distribuição de  $T$ , então tal verossimilhança seria equivalente a  $L(\theta; \mathbf{y})$ .

# Fatoração de Neyman

**Exemplo 14** Considere  $g(\cdot; \theta)$  a f.d. associada a uma a.a. simples  $\mathbf{y} = (y_1, y_2, \dots, y_n)$  obtida de forma que  $Y_i \sim \text{Bin}(1, \theta)$ .

- Temos a verossimilhança:

*[Math Processing Error]*

# Fatoração de Neyman

- Temos então que  $T(\mathbf{y}) = \sum_{i=1}^n y_i$  é uma estatística suficiente para  $\theta$  e que  $T(\mathbf{y}) \sim \text{Bin}(n, \theta)$ , em que

$$\binom{n}{t} \theta^t (1 - \theta)^{n-t}.$$

- Uma outra forma de definir estatística suficiente pode ser expressa como segue:

**Definição 9** Uma estatística  $T(\cdot)$  é suficiente para  $\theta$  se a distribuição condicional de  $Y$  dado o valor de  $T(Y)$  não depende de  $\theta$ . Em outras palavras:

$$P(Y = y | T(Y) = T(y), \theta) = P(Y = y | T(Y) = T(y)).$$

# Fatoração de Neyman

**Exemplo 15** Sejam  $(X_1, \dots, X_n)$  uma a.a. da v.a.  $X \sim Ber(\theta)$ . Verifique se  $T = \sum_{i=1}^n X_i$  suficiente para  $\theta$ .

# Fatoração de Neyman

**Exemplo 16** Considere  $\mathbf{y} = (y_1, y_2, \dots, y_n)$  uma a.a. simples da  $N(\mu, \sigma^2)$ ,

$$\begin{aligned} L(\theta; \mathbf{y}) &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2} (y_i - \mu)^2\right\} I_{(-\infty, \infty)}(y_i) \\ &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \left[\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2\right]\right\} \prod_{i=1}^n I_{(-\infty, \infty)}(y_i) \\ &= \underbrace{(2\pi)^{-n/2} \prod_{i=1}^n I_{(-\infty, \infty)}(y_i)}_{h(\mathbf{y})} \underbrace{(\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \left[\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2\right]\right\}}_{g(T(\mathbf{y})|\theta)} \end{aligned}$$

- Então  $T(\mathbf{y}) = \left(\sum_{i=1}^n y_i, \sum_{i=1}^n y_i^2\right)$  é uma estatística suficiente para  $\theta = (\mu, \sigma^2)$  de acordo com o método da fatoração de Neyman.

# Fatoração de Neyman

**Observação:** Qualquer função 1 a 1 de uma estatística suficiente também é uma estatística suficiente.

- Suponha que  $T(\mathbf{y})$  é estatística suficiente e defina  $T^*(\mathbf{y}) = r(T(\mathbf{y}))$  para todo  $\mathbf{y}$
- $r$  é uma função 1 a 1 com inversa  $r^{-1}$ .
- Teorema da Fatoração, existe  $g$  e  $h$  tal que

$$f(\mathbf{y}|\theta) = h(\mathbf{y})g[r^{-1}(T^*(\mathbf{y}))|\theta]$$

- Defina  $g^*(t|\theta) = g(r^{-1}(t)|\theta)$ , então

$$f(\mathbf{y}|\theta) = h(\mathbf{y})g^*[T^*(\mathbf{y})|\theta]$$

e pelo Teorema da Fatoração  $T^*(\mathbf{y})$  é uma estatística suficiente.

# Fatoração de Neyman

- No caso anterior considere:

$$(t_1, t_2) = \left( \sum_{i=1}^n y_i, \sum_{i=1}^n y_i^2 \right) \text{ nossa estatística suficiente para } \theta = (\mu, \sigma^2).$$

- Veja que:

$$(\bar{y}, S^2) = \left( \frac{t_1}{n}, \frac{t_2 - (t_1^2/n)}{n-1} \right) = \left( \frac{\sum_{i=1}^n y_i}{n}, \frac{\sum_{i=1}^n (y_i - \bar{y})^2}{n-1} \right)$$

que são função 1 a 1 de  $(t_1, t_2)$  com transformação inversa

$$t_1 = n\bar{y} \text{ e } t_2 = (n-1)S^2 + n\bar{y}^2.$$

- Logo,  $(\bar{y}, S^2)$  também é uma estatística suficiente para  $\theta = (\mu, \sigma^2)$ .



# Fatoração de Neyman

**Exemplo 17** Considere uma a.a.  $\mathbf{y} = (y_1, y_2, \dots, y_n)'$  da v.a.  $U(\theta, 2\theta)$ , onde  $\theta > 0$ . A f.d. associada a  $y_i$  é  $f(y_i) = \frac{1}{\theta}$ , se  $y_i \in (\theta, 2\theta)$ .

- Quando multiplicamos tais f.d.'s para obter  $L(\theta; \mathbf{y})$ , não podemos simplesmente multiplicar o termo  $1/\theta$  sem considerar a condição se  $y_i \in (\theta, 2\theta)$ .
- Portanto, escrevemos a densidade para uma única observação, como segue,

$$\frac{1}{\theta} I_{(\theta, 2\theta)}(y).$$

# Fatoração de Neyman

Função de verossimilhança

$$\begin{aligned} L(\theta; \mathbf{y}) &= \prod_{i=1}^n \frac{1}{\theta} I_{(\theta, 2\theta)}(y_i) \\ &= \frac{1}{\theta^n} \prod_{i=1}^n I_{(\theta, 2\theta)}(y_i) \end{aligned}$$

- Note que  $\prod_{i=1}^n I_{(\theta, 2\theta)}(y_i) = 1$ , se

$$\begin{array}{l} \theta < y_1 < 2\theta \\ \theta < y_2 < 2\theta \\ \vdots \\ \theta < y_n < 2\theta \end{array} \implies \theta < y_{(1)} \text{ e } \frac{y_{(n)}}{2} < \theta \implies \left[ \frac{y_{(n)}}{2} < \theta < y_{(1)} \right]$$

# Fatoração de Neyman

Assim,

$$\begin{aligned} L(\theta; \mathbf{y}) &= \frac{1}{\theta^n} \prod_{i=1}^n I_{(\theta, 2\theta)}(y_i) \\ &= \frac{1}{\theta^n} \prod_{i=1}^n I_{(y_{(n)}/2, y_{(1)})}(\theta) \end{aligned}$$

- Pelo critério da Fatoração, o par  $(y_{(1)}, y_{(n)})$  é uma estatística suficiente para  $\theta$ .

# Fatoração de Neyman

- Lembre que qualquer função 1 a 1 de uma estatística suficiente é também estatística suficiente.
- Desta forma, podemos definir inúmeras estatísticas suficientes para um dado problema.
- Poderíamos perguntar se uma estatística suficiente é melhor que as outras.
- O objetivo de uma estatística suficiente é atingir uma redução nos dados sem perder informação sobre o parâmetro  $\theta$ .
- Iremos preferir a estatística que atinge a maior redução nos dados e mantenha toda informação sobre  $\theta$

**Definição 10** Uma estatística suficiente  $T(\mathbf{y})$  é chamada de **Estatística suficiente minimal** se, para qualquer outra estatística suficiente  $T'(\mathbf{y})$ ,  $T(\mathbf{y})$  é uma função de  $T'(\mathbf{y})$ . Dizer que  $T(\mathbf{y})$  é função de  $T'(\mathbf{y})$  significa que

$$T'(\mathbf{x}) = T'(\mathbf{y}) \Rightarrow T(\mathbf{x}) = T(\mathbf{y})$$

# Fatoração de Neyman

**Exemplo 18** Duas estatísticas suficientes (caso Normal).

Já vimos anteriormente que se  $\mathbf{y} = (y_1, y_2, \dots, y_n)$  uma a.a. simples da  $N(\mu, \sigma^2)$  com  $\theta = (\mu, \sigma^2)$ , temos  $T'(\mathbf{y}) = (\bar{y}, S^2)$  como estatística suficiente para  $(\mu, \sigma^2)$ .

Se  $\sigma^2$  é conhecido, podemos usar a Fatoração de Neyman e obter

$$\begin{aligned} L(\theta; \mathbf{y}) &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2 \right]\right\} \\ &= \underbrace{(2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n y_i\right\}}_{h(\mathbf{y})} \underbrace{\exp\left\{-\frac{n}{2} \left[ \frac{\mu^2}{\sigma^2} - \frac{2}{\sigma^2} \bar{y} \right]\right\}}_{g(T(\mathbf{y})|\theta)} \end{aligned}$$

Portanto,  $T(\mathbf{y}) = \bar{y}$  é estatística suficiente para  $\mu$ .

# Fatoração de Neyman

- Se  $\sigma^2$  é conhecido, temos que  $T'(\mathbf{y}) = (\bar{y}, S^2)$  e  $T(\mathbf{y}) = \bar{y}$  são estatísticas suficientes para  $\mu$ .
- Claramente,  $T(\mathbf{y})$  atinge maior redução nos dados neste caso.
- Podemos escrever  $T(\mathbf{y})$  como função de  $T'(\mathbf{y})$  usando a seguinte igualdade:  $r(a, b) = a$ . Então,  $T(\mathbf{y}) = \bar{y} = r(\bar{y}, S^2) = r(T'(\mathbf{y}))$ .
- Como  $T(\mathbf{y})$  e  $T'(\mathbf{y})$  são ambas estatísticas suficientes, as duas possuem a mesmas informações sobre  $\mu$ .
- Então a informação adicional  $S^2$  não acrescenta nada ao nosso conhecimento de  $\mu$ , dado que  $\sigma^2$  é conhecido.
- Obviamente, se  $\sigma^2$  é desconhecido, a estatística  $T(\mathbf{y}) = \bar{y}$  deixa de ser suficiente e  $T'(\mathbf{y}) = (\bar{y}, S^2)$  passa a conter mais informação sobre  $(\mu, \sigma^2)$  do que  $T(\mathbf{y})$ .

# Estatística Suficiente Minimal

# Estatística Suficiente Minimal

- Usar a última definição para encontrar uma estatística suficiente minimal não é uma tarefa prática.
- Teríamos que adivinhar que  $T(\mathbf{y})$  é uma estatística suficiente minimal e então verificar a condição dada na definição.
- Felizmente, o seguinte resultado de Lehmann e Scheffé (1950) fornece uma maneira mais fácil de encontrar uma estatística suficiente minimal.



# Estatística Suficiente Minimal

**Teorema 5** Seja  $f(\mathbf{y})$  é uma f.d. associada com a amostra  $\mathbf{y}$ . Suponha que exista uma função  $T(\mathbf{y})$  tal que para quaisquer dois pontos amostrais  $x$  e  $y$ , a razão  $f(x|\theta)/f(y|\theta)$  é constante como função de  $\theta$  se e somente se  $T(x) = T(y)$ . Então  $T(\mathbf{y})$  é uma estatística suficiente minimal para  $\theta$ .

**Exemplo 19** Estatística suficiente minimal (caso Normal). Sejam  $(Y_1, Y_2, \dots, Y_n)$  uma a.a. simples da  $N(\mu, \sigma^2)$  com  $\theta = (\mu, \sigma^2)$  desconhecido.

Considere  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  e  $\mathbf{y} = (y_1, y_2, \dots, y_n)$  são dois pontos amostrais.

$(\bar{x}, S_x^2)$  é a média e a variância amostral de  $\mathbf{x}$

$(\bar{y}, S_y^2)$  é a média e a variância amostral de  $\mathbf{y}$

# Estatística Suficiente Minimal

- O Exemplo 19 solicita a seguinte razão:

$$\begin{aligned}
 L(\theta; \mathbf{y}) &= \frac{(2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n x_i^2 - 2\mu \sum_{i=1}^n x_i + n\mu^2 \right]\right\}}{(2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2 \right]\right\}} \\
 &= \frac{\exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (x_i + \bar{x} - \bar{x})^2 - 2n\mu\bar{x} \right]\right\} \exp\left\{-\frac{1}{2\sigma^2} n\mu^2\right\}}{\exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (y_i + \bar{y} - \bar{y})^2 - 2n\mu\bar{y} \right]\right\} \exp\left\{-\frac{1}{2\sigma^2} n\mu^2\right\}} \\
 &= \frac{\exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (x_i - \bar{x})^2 + n\bar{x}^2 - 2n\mu\bar{x}^2 \right]\right\}}{\exp\left\{-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (y_i - \bar{y})^2 + n\bar{y}^2 - 2n\mu\bar{y}^2 \right]\right\}}
 \end{aligned}$$

# Estatística Suficiente Minimal

Assim,

$$\begin{aligned} L(\theta; \mathbf{y}) &= \exp \left\{ -\frac{1}{2\sigma^2} \left[ (n-1)S_x^2 \bar{x}^2 (n-2n\mu) - (n-1)S_y^2 - \bar{y}^2 (n-2n\mu) \right] \right\} \\ &= \exp \left\{ -\frac{1}{2\sigma^2} \left[ (n-1)(S_x^2 - S_y^2)(n-2n\mu)(\bar{x}^2 - \bar{y}^2) \right] \right\} \end{aligned}$$

- Este resultado será constante como função de  $\mu$  e  $\sigma^2$  se e somente se  $\bar{x} = \bar{y}$  e  $S_x^2 = S_y^2$ .  
Então pelo [Exemplo 19](#)  $(\bar{X}, S^2)$  é uma estatística suficiente minimal para  $(\mu, \sigma^2)$ .

# Estatística Suficiente Minimal

**Exemplo 20** (Estatística suficiente minimal (caso Uniforme).) Sejam  $(X_1, X_2, \dots, X_n)$  uma a.a. simples da  $Uniforme(\theta, \theta + 1)$  com  $-\infty < \theta < \infty$ .

Considere  $\mathbf{x} = (x_1, x_2, \dots, x_n)$  e  $\mathbf{y} = (y_1, y_2, \dots, y_n)$  são dois pontos amostrais.

- A densidade para uma única observação, como segue,

$$f(x \mid \theta) = I_{(\theta, \theta+1)}(x), \quad \theta \in \mathbb{R}.$$

# Estatística Suficiente Minimal

Assim,

$$\begin{array}{l} \theta < x_1 < \theta + 1 \\ \theta < x_2 < \theta + 1 \\ \vdots \\ \theta < x_n < \theta + 1 \end{array} \implies \theta < x_{(1)} \text{ e } x_{(n)} - 1 < \theta \implies [x_{(n)} - 1 < \theta < x_{(1)}]$$

- Logo,

$$f(x \mid \theta) = I_{(x_{(n)}-1, x_{(1)})}(\theta), \quad \theta \in \mathbb{R}.$$

# Estatística Suficiente Minimal

- Então,


$$f(x \mid \theta) = I_{(x_{(n)}-1, x_{(1)})}(\theta) = \begin{cases} 1 & \text{se } x_{(n)} - 1 < \theta < x_{(1)} \\ 0 & \text{c.c.} \end{cases}$$

- De forma similar:

$$f(y \mid \theta) = I_{(y_{(n)}-1, y_{(1)})}(\theta) = \begin{cases} 1 & \text{se } y_{(n)} - 1 < \theta < y_{(1)} \\ 0 & \text{c.c.} \end{cases}$$

# Estatística Suficiente Minimal

A razão  $\frac{f(x | \theta)}{f(y | \theta)}$  será constante como função de  $\theta$  se e só  $x_{(1)} = y_{(1)}$  e  $x_{(n)} = y_{(n)}$ .



**Conclusão:**  $T(X) = (x_{(1)}, x_{(n)})$  é uma estatística suficiente minimal para  $\theta$ . Neste caso, note que a dimensão é diferente da dimensão do parâmetro.

# Família Exponencial



# Família exponencial

**Definição 11** Dizemos que a distribuição da v.a.  $Y$  pertence à família exponencial unidimensional se pudermos escrever sua f.p. ou f.d. como

$$f(y \mid \theta) = h(x)c(\theta) \exp \left\{ \sum_{i=1}^k \omega_i(\theta) t_i(y) \right\},$$

em que:

- $h(x) \geq 0$  e  $t_i(y)$ ,  $i = 1, \dots, k$ , são funções reais da observação  $y$  e são elementos que não dependem de  $\theta$ .
- $c(\theta) \geq 0$  e  $\omega_i(\theta)$ ,  $i = 1, \dots, k$ , são funções reais de  $\theta$  e são elementos que não dependem de  $y$ .

# Família exponencial

- Diversas distribuições são importantes membros da família exponencial.
- Por exemplo:
  - Caso contínuo: Normal, Gama, e Beta;
  - Binomial, Poisson, Binomial Negativa;
- Para verificar se uma certa distribuição pertence à família exponencial devemos identificar as funções  $h(y)$ ,  $c(\theta)$ ,  $t_i(y)$  e  $\omega_i(\theta)$ , e mostrar que a família pode ser escrita conforme foi expressado acima.

# Família exponencial

**Exemplo 21** Verifique se  $Y \sim \text{Binomial}(n, p)$ , pertence à família exponencial, em que  $n$  é um inteiro positivo e  $0 < p < 1$ . Nosso parâmetro de interesse é  $p$ .

$$\begin{aligned} f(y|p) &= \binom{n}{y} p^y (1-p)^{n-y} \\ &= \binom{n}{y} (1-p)^n \left( \frac{p}{1-p} \right)^y \\ &= \underbrace{\binom{n}{y}}_{h(y)} \underbrace{(1-p)^n}_{c(p)} \exp \left\{ \underbrace{y}_{t_1(y)} \underbrace{\log \left( \frac{p}{1-p} \right)}_{\omega_1(p)} \right\} \end{aligned}$$

- A família exponencial apresenta propriedades estatísticas interessantes.
- É possível tirar conclusões relevantes para uma família de distribuições sem realizar explicitamente os cálculos para cada caso específico.

# Família exponencial

**Exemplo 22** Considere  $Y = (Y_1, Y_2, \dots, Y_n)$  i.i.d  $N(\mu, \sigma^2)$ . Assim a  $f(Y|\mu, \sigma^2)$  é igual

$$\begin{aligned}
 &= \prod_{i=1}^n (2\pi\sigma^2)^{-1/2} \exp\left\{-\frac{1}{2\sigma^2}(y_i - \mu)^2\right\} I_{(-\infty, \infty)}(y_i) \\
 &= (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}\left[\sum_{i=1}^n y_i^2 - 2\mu \sum_{i=1}^n y_i + n\mu^2\right]\right\} \prod_{i=1}^n I_{(-\infty, \infty)}(y_i) \\
 &= \prod_{i=1}^n [I_{(-\infty, \infty)}(y_i)] (2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^n y_i^2\right) + \frac{2\mu}{2\sigma^2} \sum_{i=1}^n y_i\right\} \exp\left\{-\frac{1}{2\sigma^2}n\mu^2\right\} \\
 &= \underbrace{\prod_{i=1}^n [I_{(-\infty, \infty)}(y_i)]}_{h(y)} \underbrace{(2\pi\sigma^2)^{-n/2} \exp\left\{-\frac{1}{2\sigma^2}n\mu^2\right\}}_{c(\mu, \sigma^2)} \exp\left\{\underbrace{-\frac{1}{2\sigma^2}\left(\sum_{i=1}^n y_i^2\right)}_{\omega_1(\mu, \sigma^2)} \underbrace{+ \frac{\mu}{\sigma^2} \sum_{i=1}^n y_i}_{t_1(y)} \underbrace{- \frac{1}{2\sigma^2}n\mu^2}_{\omega_2(\mu, \sigma^2)}\right\}
 \end{aligned}$$

# Família exponencial

- É fácil encontrar uma estatística suficiente para uma distribuição da família exponencial. Considere o teorema abaixo.

**Teorema 6** Sejam  $Y_1, Y_2, \dots, Y_n$  observações i.i.d. de uma f.d. ou f.p  $f(Y \mid \theta)$  que pertence à família exponencial dada por

$$f(y \mid \theta) = h(x)c(\theta) \exp \left\{ \sum_{i=1}^k \omega_i(\theta) t_i(y) \right\},$$

sendo  $\theta = (\theta_1, \theta_2, \dots, \theta_d)$ ,  $d \leq K$ .

Então,  $T(Y) = (t_1(y), t_2(y), \dots, t_k(y))$  é uma estatística suficiente para  $\theta$ .

# Família exponencial

**Prova:** Considere o teorema da fatoração de Neyman

$$f(y \mid \theta) = h(x)c(\theta) \underbrace{\exp \left\{ \sum_{i=1}^k \omega_i(\theta) t_i(y) \right\}}_{g(T(Y) \mid \theta)},$$

- Então,  $T(Y) = (t_1(y), t_2(y), \dots, t_k(y))$  é uma estatística suficiente para  $\theta$ .
- No exemplo anterior (caso Normal) temos  $t_1(Y) = \sum_{i=1}^n Y_i^2$  e  $t_2(Y) = \sum_{i=1}^n Y_i$ .

Então,  $\left( \sum_{i=1}^n Y_i^2, \sum_{i=1}^n Y_i \right)$  é estatística suficiente para  $(\mu, \sigma^2)$ .

# Ancilaridade e Completude

# Ancilaridade

- Consideramos anteriormente as estatísticas suficientes. Estas estatísticas contêm toda a informação sobre  $\theta$  que está disponível na amostra.
- Iremos introduzir agora um tipo diferente de estatística; ela apresenta um conceito oposto.

**Definição 12** Uma estatística  $S(X)$  cuja distribuição não depende do parâmetro de interesse  $\theta$  é dita **estatística ancilar**.

- Uma estatística ancilar não contém informação sobre  $\theta$ . Ela é uma observação de uma variável aleatória cuja distribuição é fixa e conhecida (sem relação com  $\theta$ ).
- Paradoxalmente, uma estatística ancilar usada em conjunto com outras estatísticas pode conter informação sobre  $\theta$ .



# Ancilaridade

**Exemplo 23** Sejam  $X_1, \dots, X_n$  observações iid de uma distribuição pertencente à família de locação com f.d.a  $F(x - \theta)$  sendo  $-\infty < \theta < \infty$ . A diferença  $R = X_{(n)} - X_{(1)}$  é uma estatística ancilar?

Assuma que  $X_1 = Z_1 + \theta, X_2 = Z_2 + \theta, \dots, X_n = Z_n + \theta$  sendo  $Z_1, \dots, Z_n$  observações iid com f.d.a.  $F(X)$ .

A f.d.a. de  $R$  será

$$F_R(r | \theta) = P[R \leq r] = P\left[\max_i(X_i) - \min_i(X_i) \leq r\right]$$

Logo,

$$\begin{aligned} F_R(r | \theta) &= P[\max_i(Z_i + \theta) - \min_i(Z_i + \theta) \leq r] \\ &= P[\max_i(Z_i) + \theta - \min_i(Z_i) - \theta \leq r] \\ &= P[\max_i(Z_i) - \min_i(Z_i) \leq r] \end{aligned}$$

Esta f.d.a. não depende de  $\theta$ , logo  $R$  é uma estatística ancilar.

# Ancilaridade

**Exemplo 24** Sejam  $X_1, \dots, X_n$  observações iid de uma distribuição pertencente à família de escala com f.d.a  $F(x/\sigma)$  sendo  $0 < \theta < \infty$ . Qualquer estatística, que dependa da amostra apenas através de  $n - 1$  valores do tipo  $X_1/X_n, \dots, X_{n-1}/X_n$  será ancilar.

Por exemplo:

$$\frac{X_1 + \dots + X_n}{X_n} = X_1/X_n + \dots + X_{n-1}/X_n + 1, \text{ é ancilar.}$$

Seja  $Z_1, \dots, Z_n$  observações iid com f.d.a  $F(x)$  (temos aqui  $\sigma = 1$ ). Defina  $X_1 = \sigma Z_1, \dots, X_n = \sigma Z_n$ .

A f.d.a conjunta de  $X_1/X_n, \dots, X_{n-1}/X_n$  é dada por

$$\begin{aligned} F(y_1, \dots, y_{n-1} \mid \sigma) &= P[X_1/X_n \leq y_1, \dots, X_{n-1}/X_n \leq y_{n-1}] \\ &= P\left[\frac{\sigma Z_1}{\sigma Z_n} \leq y_1, \dots, \frac{\sigma Z_{n-1}}{\sigma Z_n} \leq y_{n-1}\right] \\ &= P\left[\frac{Z_1}{Z_n} \leq y_1, \dots, \frac{Z_{n-1}}{Z_n} \leq y_{n-1}\right] \end{aligned}$$

# Ancilaridade

A última probabilidade não depende de  $\sigma$  visto que a distribuição de  $Z_1, \dots, Z_n$  não depende de  $\sigma$ .

Portanto, a distribuição de  $X_1/X_n, \dots, X_{n-1}/X_n$  não dependerá de  $\sigma$ , assim como a distribuição de qualquer função destas quantidades.

Caso particular:  $X_1$  e  $X_2$  são iid.  $N(0, \sigma^2)$

O resultado acima indica que  $X_1/X_2$  tem distribuição que não depende de  $\sigma$ .

É possível mostrar que  $X_1/X_2 \sim \text{Cauchy}(0, 1)$  para qualquer  $\sigma > 0$

# Ancilaridade

- Uma estatística suficiente minimal é aquela que atinge a maior redução de dados possível, mantendo toda informação sobre  $\theta$ .
- Intuitivamente, uma estatística suficiente minimal elimina toda a informação irrelevante na amostra, restando apenas aquilo que interessa sobre  $\theta$ .
- A distribuição de uma estatística ancilar não depende de  $\theta$ , então poderíamos suspeitar que uma estatística suficiente minimal não tem relação com estatísticas acilares.
- Entretanto, isso não é necessariamente verdade.
- Investigaremos esta relação a seguir...

# Ancilaridade

- É possível mostrar que se  $X_1, \dots, X_n$  são iid com distribuição  $U(\theta, \theta + 1)$ , então  $\left[ X_{(n)} - X_{(1)}, \frac{X_{(1)} + X_{(n)}}{2} \right]$  é uma estatística suficiente minimal para  $\theta$ .
- Temos também o seguinte resultado  $X_{(n)} - X_{(1)}$  é estatística ancilar. (Ver, Casella e Berger(2002), pag. 282 e 283).
- Neste caso, a estatística ancilar é uma **componente importante** na formulação da estatística minimal.
- Aqui, estes dois tipos de estatísticas não são independentes.
- Para dar uma ideia de como uma estatística ancilar pode trazer informação sobre  $\theta$ , considere o próximo exemplo.

# Ancilaridade

**Exemplo 25** Caso particular:  $X_1$  e  $X_2$  são iid com f.p.

$$P(X = \theta) = P(X = \theta + 1) = P(X = \theta + 2) = \frac{1}{3},$$

sendo  $\theta$  um inteiro desconhecido.

Esta distribuição é da família de locação.

Estatísticas de ordem:  $X_{(1)} \leq X_{(2)}$ .

Assuma  $R = X_{(2)} - X_{(1)}$  e  $M = \frac{X_{(1)} + X_{(2)}}{2}$ .

Estatística suficiente minimal para  $\theta : [R, M]$ .

Estatística ancilar:  $R$ .

Considere o ponto  $[R, M] = (r, m)$ , sendo  $m$  inteiro.

# Ancilaridade

- $M = \frac{X_{(1)} + X_{(2)}}{2}$  então temos as seguintes possibilidades para  $m$ :

$$m = \frac{\theta + \theta}{2} = \theta$$

$$m = \frac{\theta + (\theta + 1)}{2} = \theta + \frac{1}{2}$$

$$m = \frac{\theta + (\theta + 2)}{2} = \theta + 1$$

$$m = \frac{(\theta + 1) + (\theta + 1)}{2} = \theta + 1$$

$$m = \frac{(\theta + 1) + (\theta + 2)}{2} = \theta + \frac{3}{2}$$

$$m = \frac{(\theta + 2) + (\theta + 2)}{2} = \theta + 2$$

Lembre que  $\theta$  e  $m$  são inteiros, logo podemos ter  $m = \theta$ ,  $m = \theta + 1$  ou  $m = \theta + 2$ , quando dispomos apenas da informação de  $M = m$  (Estatística suficiente minimal).

# Ancilaridade

Suponha agora que  $R = 2$  é uma informação adicional obtida.  $R = X_{(2)} - X_{(1)}$

$X_{(1)}$	$X_{(n)}$	$m$	$r$
$\theta$	$\theta$	$\theta$	0
$\theta$	$\theta + 2$	$\theta + 1$	2
$\theta + 1$	$\theta + 1$	$\theta + 1$	0
$\theta + 2$	$\theta + 2$	$\theta + 2$	0

**Conclusão:** O conhecimento de uma estatística ancilar ( $R$ ) aumentou nosso conhecimento sobre  $\theta$ .

O conhecimento do valor de  $R$  sozinho, não traria qualquer informação sobre o valor de  $\theta$  (no caso  $r=2$ , saberíamos que  $X_{(1)} = \theta$  e  $X_{(2)} = \theta + 2$  mas não teríamos  $m$  para determinar  $\theta$ ).



# Completeness

- Para muitas situações, entretanto, nossa intuição de que uma *estatística suficiente minimal* é independente de qualquer *estatística ancilar* está correta.
- Os casos onde isso ocorre tem como base a seguinte definição:

**Definição 13** Uma estatística  $T = T(X_1, \dots, X_n)$  é dita ser completa em relação à família  $f(x | \theta), \theta \in \Theta$ , se a única função real  $g$ , definida no domínio de  $T$ , tal que  $E(g(T)) = 0$  para todo  $\theta$  é a função nula, isto é,  $g(T) = 0$  com probabilidade um.

$T$  é completa se, e somente se,  $E(g(T(\mathbf{X}))) = 0, \theta \in \Theta$ , implicar que  $P(g(T(\mathbf{X})) = 0) = 1, \theta \in \Theta$ .

- Note que a *completeness* é uma propriedade de uma família de distribuições, e não de uma distribuição particular.

# Completude

**Exemplo 26**  $X \sim N(0, 1)$  e  $g(X) = X$ . Então,

$$E(g(X) = X) = E(X) = 0.$$

Entretando,  $P(g(X) = 0) = P(X = 0) \neq 1$ . Note que a  $N(0, 1)$  é uma distribuição particular.

**Exemplo 27**  $X \sim N(\theta, 1)$  com  $\theta \in \mathbb{R}$ . Nenhuma função de  $X$ , exceto  $g(X) = 0$  para todo  $\theta$ , satisfaz  $E[g(X)] = 0$  para todo  $\theta$ .

Então temos que  $E[g(X)] = 0 \Rightarrow P(g(X) = 0) = 1, \forall \theta$ .

Dessa forma, a família de distribuições  $X \sim N(\theta, 1)$  é completa.

# Completeness

**Exemplo 28** Suponha que  $T \sim \text{Binomial}(n, p)$ , com  $0 < p < 1$ .

Seja  $g$  uma função tal que  $E_p(g(T)) = 0$ .

Então,

$$\begin{aligned} 0 = E_p[g(T)] &= \sum_{t=0}^n g(t) \binom{n}{t} p^t (1-p)^{n-t} \\ &= (1-p)^n \sum_{t=0}^n g(t) \binom{n}{t} \left(\frac{p}{1-p}\right)^t, \quad \forall p. \end{aligned}$$

O componente  $(1-p)^n \neq 0$  para qualquer  $p \in (0, 1)$ .

Então devemos ter:

$$0 = \sum_{t=0}^n g(t) \binom{n}{t} r^t,$$

com  $r = \frac{p}{1-p} \in (0, \infty)$ .

# Completude

- A última expressão é um polinômio de grau  $n$  em  $r$ , onde o coeficiente  $r^t$  será  $g(t) \binom{n}{t}$ .  
Para que o polinômio se  $0 \forall r$  cada coeficiente deve ser 0.
- Veja, que  $\binom{n}{t} \neq 0$ , então  $g(t) = 0$ , para  $t = 0, 1, \dots, n$ .
- Dado que  $T = 0, 1, \dots, n$ , temos que  $E_p [g(T)] = 0 \Rightarrow P_p(g(T) = 0) = 1, \forall p$ .

**Conclusão:**  $T$  é uma estatística completa.

# Completeness

- The theorem below uses completeness to establish a condition under which a minimal sufficient statistic is independent of every ancillary statistic.

**Theorem 7 (Theorem of Basu)** If  $T(X)$  is a minimal complete sufficient statistic, then  $T(X)$  is independent of every ancillary statistic.

- The Theorem of Basu allows us to deduce independence of two statistics without having to find their joint distribution.
- To use the Theorem of Basu, we need to show that the statistic is complete.
- Often, this is a difficult task in terms of analysis.
- Fortunately, most of the problems we will work on use the following result.

# Compleitude

## Teorema 8 (Estatística completa da família exponencial.)

Seja  $X_1, \dots, X_n$  observações iid de uma distribuição da Família Exponencial com f.d. ou f.p. do tipo

$$f(x \mid \theta) = h(x)c(\theta) \exp \left\{ \sum_{j=1}^k \omega_j(\theta) t_j(x) \right\}, \quad \theta = (\theta_1, \theta_2, \dots, \theta_k)'$$

Então a estatística  $T(X) = \left[ \sum_{i=1}^n t_1(x), \sum_{i=1}^n t_2(x), \dots, \sum_{i=1}^n t_k(x) \right]$  é completa se e somente se  $\{[\omega_1(\theta), \dots, \omega_k(\theta)] : \theta \in \Theta\}$  contém um conjunto aberto em  $\mathbb{R}^k$ . :::

# Completude

- A condição de que o espaço paramétrico contenha um conjunto aberto é necessária para evitar a seguinte situação:

A  $N(\theta, \theta^2)$  é membro da família exponencial.

$$\text{Verossimilhança: } (2\pi\theta^2)^{-n/2} \exp\left\{-\frac{1}{2\theta^2} \left[\sum_{i=1}^n y_i^2 - 2\theta \sum_{i=1}^n y_i + n\theta^2\right]\right\}$$

Formulação da FE:

$$\underbrace{(2\pi)^{-n/2}}_{h(x)} \underbrace{\theta^{-n}}_{c(\theta)} \exp\left\{\underbrace{\frac{1}{\theta^2}}_{\omega_1(\theta)} \left[ -\frac{1}{2} \underbrace{\sum_{i=1}^n y_i^2}_{t_1(x)} \right] + \underbrace{\frac{1}{\theta}}_{\omega_2(\theta)} \underbrace{\sum_{i=1}^n y_i}_{t_1(x)} \right\}$$

$\{\omega_1(\theta), \omega_2(\theta)\} = \left\{ \frac{1}{\theta^2}, \frac{1}{\theta} \right\}$  que possui uma relação muito próxima com o espaço paramétrico  $\{\theta, \theta^2\}$ .

# Completude

!()[figura\_aberto.jpg]

**Conclusão:**  $\{\omega_1(\theta), \omega_2(\theta)\}$  não contém um aberto em  $\mathbb{R}^2$ , então

$$T(X) = \left[ t_1(x) = -\frac{1}{2} \sum_{i=1}^n X_i^2, t_2(x) = \sum_{i=1}^n X_i \right]$$

não é uma estatística completa.